

Reporte del sistema actual de Gemelo Digital SIMION

Versión interna para poner al grupo al día

Fecha de generación: 2026-07-01. Este documento describe la versión actual elegida del sistema: emulación por ensemble MLP diferenciable, diseño inverso por gradiente y recolección activa orientada a información útil.

1. Resumen ejecutivo

Construimos un gemelo digital del beamline de SIMION. En palabras simples: una red neuronal aprende a imitar el resultado de SIMION a partir de los voltajes de control. Una vez entrenado, el gemelo responde en milisegundos, se puede derivar y permite buscar voltajes sin pagar una corrida completa de SIMION en cada intento.

- Entrada del modelo: ocho voltajes libres del montaje.
- Salidas principales: transmisión activa, fracción forward, ángulo medio de impacto, dispersión angular y una corrección residual para la dispersión de velocidad longitudinal.
- Uso directo: dados unos voltajes, predice las métricas del haz.
- Uso inverso: dada una consigna de transmisión/ángulo, optimiza los voltajes de entrada sobre el propio gemelo y luego valida en SIMION.
- Fortaleza actual: buena predicción cerca de la región informativa y control inverso validado de transmisión en un rango amplio.
- Cuidado principal: las regiones de baja transmisión son físicamente más abruptas y tienen peor calidad angular; el gemelo debe reportar incertidumbre y no venderlas como iguales a la región de alta transmisión.

2. Qué problema resuelve

El reto pide un emulador que reciba voltajes y devuelva una o varias cantidades de interés del beamline. Nuestro sistema no busca reemplazar SIMION para siempre: busca usar SIMION como fuente de datos cara, aprender una aproximación rápida y usar esa aproximación para control.

El haz de entrada se mantiene fijo en el reto: misma partícula, energía y distribución inicial. Por eso el cambio en las métricas se atribuye a los voltajes. Esto simplifica el problema: el gemelo no necesita generalizar todavía a masa/carga o energía distinta.

3. Variables del sistema

3.1 Voltajes de entrada

El modelo trabaja con los ocho voltajes libres indicados por la guía del reto: V3, V6, V9, V10, V11, V12, V15 y V18. El resto se mantiene fijo, por ejemplo V1=500 V y V19=-2000 V para el detector.

Tipo	Variables
Voltajes libres	V3, V6, V9, V10, V11, V12, V15, V18
Voltajes fijos	V1=500, V2=0, V4=0, V5=0, V7=0, V8=0, V13=0, V14=0, V16=0, V17=0, V19=-2000

3.2 Métricas de salida

Métrica	Qué significa	Uso
transmisión activa	fracción de iones que impactan la ventana activa del detector	objetivo principal
forward fraction	fracción que llega con dirección válida	admisibilidad física

Métrica	Qué significa	Uso
theta_mean	ángulo medio de impacto	calidad del haz
theta_sigma	dispersión angular	enfoque/paralelismo
vz_sigma residual	corrección aprendida sobre una fórmula física simple	salida auxiliar de velocidad

4. Cómo corre el sistema completo

El flujo tiene cinco capas. La primera habla con SIMION; la segunda guarda datos; la tercera entrena el gemelo; la cuarta usa el gemelo para predecir; y la quinta usa gradientes para diseño inverso.

Etapas	Qué hace	Archivo principal
SIMION/Lua	Vuela iones, calcula impactos y métricas	SimpleSetUp.lua / optimize.py
Dataset	Guarda voltajes y métricas reales	dt/data/dt_detector_window_dataset.csv
Entrenamiento	Ajusta ensemble MLP por backpropagation	dt/train_dt.py
Predicción	Voltajes -> métricas predichas + incertidumbre	dt/predict_dt.py
Control inverso	Consigna -> voltajes candidatos	dt/inverse_design.py
Validación	Candidatos -> SIMION real	dt/validate_candidates.py
Aprendizaje activo	Pide nuevos puntos donde el modelo falla o duda	dt/*active*.py




Figura 1. Montaje físico del beamline usado por SIMION.

5. Modelo elegido

El modelo actual es un ensemble de redes neuronales MLP multitarea. Ensemble significa que entrenamos varias redes con semillas distintas y promediamos sus respuestas. El promedio es la predicción; el desacuerdo entre redes sirve como una estimación práctica de incertidumbre.

Durante entrenamiento, los voltajes y las salidas se escalan para evitar que la red aprenda mal por diferencias de unidades. Los pesos se ajustan por backpropagation con AdamW y una pérdida log-cosh ponderada. Esta pérdida es más robusta que MSE ante puntos raros o transiciones abruptas.

Componente	Estado actual
Arquitectura	Ensemble de MLPs multitarea

Componente	Estado actual
Capas ocultas	128, 128, 64
Activación	GELU
Regularización	Dropout 0.03 + weight decay
Optimizador	AdamW
Pérdida	log-cosh ponderada por relevancia física
Diferenciabilidad	Sí; PyTorch permite gradiente respecto a pesos y voltajes

5.1 Qué significa entrenar el DT

Cada fila del dataset tiene esta forma: ocho voltajes de entrada y las métricas reales devueltas por SIMION. La red recibe los voltajes, produce métricas predichas y se compara contra las métricas reales. Esa diferencia genera una pérdida. Con backpropagation se calcula cómo debería cambiar cada peso de la red para reducir esa pérdida. Este ciclo se repite por muchas épocas.

Paso	Descripción
1. Entrada	Se normaliza el vector de voltajes.
2. Predicción	Cada MLP estima transmisión, forward fraction, ángulos y residual de velocidad.
3. Error	Se compara contra SIMION usando log-cosh ponderado.
4. Backpropagation	PyTorch calcula gradientes respecto a los pesos.
5. Actualización	AdamW modifica los pesos.
6. Ensemble	Se repite para varias semillas; la media predice y la dispersión indica incertidumbre.

5.2 Por qué ensemble y no una sola red

El transporte iónico en este montaje no es una función perfectamente suave: pequeños cambios de voltaje pueden convertir un haz transmitido en un haz recortado por una apertura. Una sola red puede suavizar demasiado esos acantilados. El ensemble ayuda en dos sentidos: reduce varianza al promediar y permite detectar regiones donde varios modelos no están de acuerdo.

5.3 Métrica de velocidad: física primero, red después

La rapidez total de los iones resultó casi constante en las validaciones. Por eso no entrenamos una distribución completa de velocidades como caja negra. En su lugar calculamos una base física a partir de θ_{mean} y θ_{sigma} , y la red solo aprende el residual de v_{sigma} . Esto reduce complejidad y mantiene una interpretación física clara.

6. Datos disponibles y cobertura

El dataset base actual contiene 3272 filas. Todas entrenan transmisión y ángulos; 1702 filas contienen además información suficiente para entrenar el residual de v_{sigma} .




Figura 2. Cobertura del dataset por rangos de transmisión activa.

7. Desempeño del gemelo directo

La validación interna separa datos de entrenamiento y validación. La métrica principal se reporta como MAE: error absoluto medio. En transmisión, 0.030 significa aproximadamente 3.0 puntos porcentuales.

Métrica	MAE global	MAE high-contact	Interpretación
Transmisión activa	0.0302	0.0148	fracción; 0.03 = 3 pp
Forward fraction	0.0482	0.0015	fracción direccional
theta_mean	0.7834	0.1171	grados
theta_sigma	0.4829	0.1165	grados
vz_sigma residual	0.1606	0.0483	corrección sobre física base

La diferencia entre error global y error high-contact es importante: la región informativa del reto es donde de verdad llegan iones. Allí el modelo es más preciso que en el promedio global, porque las zonas de transición y clipping son físicamente más abruptas.

8. Diseño inverso y control

El diseño inverso usa el mismo gemelo, pero al revés. No entrenamos otra red para invertir. Congelamos los pesos y tratamos los voltajes como variables optimizables. Por gradiente buscamos voltajes cuya salida predicha se acerque a una consigna.

Este punto es central para la guía del reto: el gemelo no solo debe predecir una tabla, debe servir para controlar la máquina. Por eso validamos las consignas inversas volviendo a SIMION.

Ejemplo conceptual: si pedimos 70% de transmisión, theta_mean cercano a 4° y theta_sigma cercano a 2°, el algoritmo inicia desde muchas combinaciones de voltajes, evalúa el DT, calcula una pérdida de consigna y ajusta los voltajes por gradiente. Los mejores candidatos se exportan y se validan en SIMION.

Objetivo	SIMION	theta_mu	theta_sigma	Comentario
20%	19.0%	9.237°	6.189°	baja transmisión, calidad angular degradada

Objetivo	SIMION	theta_mu	theta_sigma	Comentario
30%	30.4%	5.651°	2.739°	familia baja viable
40%	40.6%	5.556°	2.922°	control razonable
50%	50.4%	5.048°	2.494°	control medio estable
70%	69.6%	4.770°	2.291°	zona media-alta
90%	91.4%	3.554°	1.589°	alta transmisión
100%	100.0%	2.301°	1.148°	óptimo práctico

La zona de 20--30% existe, pero el haz llega más degradado angularmente. Para reportes y demostraciones conviene distinguir entre control de transmisión y calidad del haz.

8.1 Optimización de dirección

Para dirección, el objetivo natural es maximizar transmisión y, dentro de los puntos de transmisión alta, preferir haces más paralelos. En nuestras soluciones de alta transmisión se alcanzó 100% de contacto activo con θ_{mean} cercano a 2° y θ_{sigma} del orden de 1°. Esto es el régimen que conviene usar como demostración de buen punto de operación.

8.2 Consigna inversa

Para consigna inversa, la dificultad no es encontrar el máximo, sino producir voluntariamente diferentes niveles de transmisión. Esto obliga al DT a aprender zonas medias y bajas. Las validaciones consolidadas muestran control amplio de transmisión, pero con una advertencia: a menor transmisión, la calidad angular tiende a empeorar porque muchas soluciones de baja transmisión funcionan recortando o seleccionando parte del haz.

9. Aprendizaje activo y eficiencia de datos

Además del banco grande, implementamos un modo presupuestado: el sistema recibe un número máximo de consultas a SIMION y decide dónde medir. Este modo no reinicia al pasar de 100 a 200 puntos; crece incrementalmente y toma snapshots para estimar cuántos puntos son necesarios.

La evidencia actual sugiere que cerca de 500 puntos el modelo empieza a ser funcional, mientras que 900--1000 puntos dan un umbral más defendible para predicción y consigna inversa. Esto no significa que siempre se requieran 1000 puntos: la estrategia actual explora loops orientados a fallos de consigna inversa para intentar bajar ese umbral.

9.1 Dos modos de recolección actuales

Modo	Idea	Uso recomendado
budget_simion_loop	Selecciona puntos por incertidumbre, cuotas de transmisión y diversidad.	Estimar eficiencia de datos y entrenar con presupuesto cerrado.
inverse_active_loop	Pide consignas inversas, valida los fallos en SIMION y reentrena.	Mejorar específicamente la tarea de consigna inversa.

El segundo modo es más reciente. Nació porque la rúbrica no evalúa solo predicción directa: también evalúa si el gemelo puede controlar. Por eso estamos agregando datos donde el control inverso se equivoca, no solo donde la incertidumbre genérica es alta.

9.2 Qué significa eficiencia en nuestro caso

Eficiencia no significa usar pocos puntos a cualquier costo. Significa lograr un modelo útil con el mínimo número de consultas a SIMION. En un espacio de ocho dimensiones con regiones muertas y transiciones abruptas, 100 puntos no bastan para el modelo actual; 500 puntos dan un sistema funcional; y alrededor de 900--1000 puntos el comportamiento ya es defendible. Estos valores se reportan como curva de aprendizaje, no como dogma.

10. Cómo respondemos a la rúbrica del reto

Criterio	Cómo lo aborda nuestro sistema
C - Dirección	Usa diseño inverso sobre el DT para maximizar transmisión y reducir dispersión angular; soluciones de 100% transmisión ya fueron validadas.
A - Exactitud	MAE high-contact aprox. 1.5 puntos porcentuales en transmisión y $\sim 0.12^\circ$ en $\theta_{\text{mean}}/\theta_{\text{sigma}}$.
I - Consigna inversa	Barridos validados muestran control de transmisión desde $\sim 20\%$ hasta 100%, con degradación angular en baja transmisión.
E - Extrapolación/honestidad	Ensemble entrega incertidumbre; se distinguen regiones confiables de regiones abruptas o de baja calidad angular.
D - Diferenciabilidad	El modelo PyTorch es diferenciable; se optimizan voltajes por gradiente sobre el gemelo.
F - Eficiencia de datos	Hay loops presupuestados e incrementales para estimar el mínimo de puntos; 500 funcional, ~ 900 -- 1000 recomendado.
G - Admisibilidad	Las salidas se recortan a rangos físicos y las métricas de ángulo solo se calculan sobre impactos válidos en ventana activa.

11. Límites y confianza actual

- Confiamos más en la región de transmisión media-alta y alta, especialmente cuando hay impactos forward en la ventana activa.
- La región de baja transmisión se puede controlar, pero suele implicar clipping del haz y peor ángulo; por tanto no debe venderse como una solución tan limpia como 80--100%.
- El modelo actual no generaliza a otra partícula, energía o geometría sin recolectar nuevos datos. En el reto esto no es problema porque esas condiciones son fijas.
- La incertidumbre del ensemble es útil como señal de honestidad, pero no es una garantía estadística perfecta.
- El loop inverso activo está en desarrollo: su objetivo es reducir el presupuesto necesario enfocándose en los fallos de consigna, no reemplazar aún al modelo base validado.

11.1 Qué no estamos afirmando

No afirmamos que la red haya aprendido toda la física interna del beamline. Afirmamos que aprendió un mapa útil entre voltajes y métricas bajo las condiciones fijas del reto. Tampoco afirmamos que la baja transmisión sea igual de buena que la alta: puede cumplir transmisión objetivo, pero con mayor ángulo y dispersión.

11.2 Qué sí podemos defender

- El flujo completo existe: SIMION -> dataset -> entrenamiento -> predicción -> diseño inverso -> validación.
- El modelo es diferenciable y se usa efectivamente para optimizar voltajes.
- Las salidas son admisibles y se calculan sobre impactos físicos válidos.
- El sistema distingue regiones informativas de regiones muertas o abruptas.
- La bitácora conserva decisiones y resultados para reproducibilidad.

12. Archivos clave para el grupo

Archivo	Función
dt/dt_config.json	configuración de voltajes, bounds, targets e hiperparámetros
dt/train_dt.py	entrenamiento del ensemble MLP
dt/predict_dt.py	predicción directa
dt/inverse_design.py	diseño inverso diferenciable
dt/validate_candidates.py	validación de candidatos en SIMION
dt/budget_simion_loop.py	entrenamiento autónomo con presupuesto

Archivo	Función
dt/inverse_active_loop.py	aprendizaje activo orientado a fallos de consigna inversa
dt/EXPERIMENT_LOG.md	registro de decisiones y resultados validados

13. Guía práctica para el equipo

Si alguien del grupo quiere entender o ejecutar el sistema sin entrar en todos los detalles, puede pensar en tres comandos: entrenar, predecir y validar diseño inverso. En la práctica, durante el hackathon conviene no modificar la geometría ni los PA salvo que sea estrictamente necesario; para cambiar voltajes usamos fastadj.

Objetivo	Comando/base
Entrenar modelo principal	.\venv\Scripts\python.exe .\dt\train_dt.py
Predecir métricas para voltajes	.\venv\Scripts\python.exe .\dt\predict_dt.py --voltages V3=... V6=...
Diseño inverso	.\venv\Scripts\python.exe .\dt\inverse_design.py --target-active ...
Validar candidatos en SIMION	.\venv\Scripts\python.exe .\dt\validate_candidates.py --top 5
Ver bitácora	dt\EXPERIMENT_LOG.md

14. Mensaje final

La versión actual es un primer gemelo digital completo y defendible: no es solo un optimizador de voltajes ni solo una red que ajusta una tabla. Es un ciclo de control: aprende de SIMION, predice, propone voltajes y vuelve a validar. Para el grupo, la prioridad ahora no es cambiar toda la arquitectura, sino consolidar evidencia: figuras predicho-vs-real, curva de aprendizaje, control inverso y ejemplos claros de dónde el modelo confía y dónde no.